

传统利率期限结构模型比较

一、Model

已知利率 R 和时间 t 的观测数据，用三个回归模型进行拟合。

- Nelson-Siegel 模型：

$$R = \beta_0 + \beta_1 \frac{1 - e^{-t/\gamma}}{t/\gamma} + \beta_2 \left[\frac{1 - e^{-t/\gamma}}{t/\gamma} - e^{-t/\gamma} \right]$$

其中 $\gamma \in [0,10]$ 。

- Nelson-Siegel Svensson 扩展模型：

$$R = \beta_0 + \beta_1 \frac{1 - e^{-t/\gamma_1}}{t/\gamma_1} + \beta_2 \left[\frac{1 - e^{-t/\gamma_1}}{t/\gamma_1} - e^{-t/\gamma_1} \right] + \beta_3 \left[\frac{1 - e^{-t/\gamma_2}}{t/\gamma_2} - e^{-t/\gamma_2} \right]$$

- Nelson-Siegel & Lasso 回归模型：

$$R = \beta_0 + \beta_1 \frac{1 - e^{-t/\gamma_1}}{t/\gamma_1} + \sum_{i=1}^{10} \beta_{i+1} \left[\frac{1 - e^{-t/\gamma_i}}{t/\gamma_i} - e^{-t/\gamma_i} \right]$$

上式其中 $\gamma_i = i$ ，且 β_1 必须为非 0。

二、Data Describe

train: 训练集，共 66 天，对每天数据进行拟合，得到66×3个回归方程。

test: 测试集，共 66 天，用于对上面拟合出的模型进行验证。成绩计算：

$$RMSE = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n}}$$

$$MAPE = \frac{\sum |y_i - \hat{y}_i|}{y_i} / n$$

自变量为时间 t ，因变量为利率 r 。其余字段可以不理。

三、Task

- 拟合出各个模型的未知参数，并把每天的回归参数结果汇总在一个表中。
- 画出每天的拟合效果图。
- 对于模型三，还要画出正则系数 α 与拟合误差($RMSE$ 、 $MAPE$)、非零回归系数 β 个数的关系图。
- 把所有天数的预测函数图汇总在一起。

四、Solving for Nelson-Siegel & Lasso

对于一般回归模型的求解目标函数为误差的平方和最小：

$$\operatorname{argmin}_{\boldsymbol{\beta}} L(X; \boldsymbol{\beta}) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - \widehat{y}^{(i)})^2$$

其中

$$\widehat{y}^{(i)} = f(X^{(i)}; \boldsymbol{\beta}) = [1, X^{(i)}] \cdot \boldsymbol{\beta} = \beta_0 + \sum_{k=1}^d \beta_k X_k^{(i)}$$

$X^{(i)}$ 为第 i 个样本 d 维输入向量， $X^{(i)} = [X_1^{(i)}, X_2^{(i)}, \dots, X_d^{(i)}]$ ；

$\boldsymbol{\beta}$ 为 $d + 1$ 维参数向量， $\boldsymbol{\beta} = [\beta_0, \beta_1, \dots, \beta_d]^T$ ；

$\widehat{y}^{(i)}$ 第 i 个样本 d 的拟合函数输出；

$X_k^{(i)}$ 为第 i 个样本第 k 维的输入值。

Note: $L(X; \boldsymbol{\beta})$ 中前面的系数不影响参数求解

对于 Lasso 回归，则需要在损失函数中引入 $L1$ 正则。求解目标变成：

$$\operatorname{argmin}_{\boldsymbol{\beta}} L(X; \boldsymbol{\beta}) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - \widehat{y}^{(i)})^2 + \alpha \|\boldsymbol{\beta}\|_1$$

其中 $\|\boldsymbol{\beta}\|_1 = |\beta_0| + |\beta_1| + \dots + |\beta_d|$

而在本模型中,由于目标函数中 β_1 必须保留,而后面的自变量作 Lasso 回归,故损失函数为:

$$\operatorname{argmin}_{\beta} L(X; \beta) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - \widehat{y^{(i)}})^2 + \alpha \sum_{i=2}^{11} |\beta_i|$$

对于模型求解,一般用于梯度下降法,而针对 Lasso 回归,还可以应用最小角回归求解。在此引用第三种巧妙的求解思路:

先对原回归函数中第三项(包括第三项)后面的进行单独的 Lasso 回归:

$$y_half = \sum_{i=1}^{10} \beta_{i+1} \left[\frac{1 - e^{-t/\gamma_i}}{t/\gamma_i} - e^{-t/\gamma_1} \right]$$

回归的因变量还是原来的利率 r , 得出后面 10 个 Lasso 回归参数

$$\beta_{half} = [\beta_2, \dots, \beta_{11}]$$

再把 y_half 看成新的自变量,再与原模型前两项作一般线性回归:

$$R = \beta_0 + \beta_1 \frac{1 - e^{-t/\gamma_1}}{t/\gamma_1} + w \cdot y_half$$

其中 w 为新回归项 y_half 的回归系数。

求解出 w 后再乘以原来的 $\beta_{half} = [\beta_2, \dots, \beta_{11}]$,这样可以得出所有的回归参数,即:

$$[\beta_2, \dots, \beta_{11}] := w \cdot [\beta_2, \dots, \beta_{11}]$$

这种求解方法利用了线性回归的线性可加性,使用的前提假设为原模型中各个回归自变量独立不相关,但在本模型中明显不满足这前提假设。但可以用于特征选择。